

Обзор современных нейросетевых оптимизаторов

Колпащиков Максим

March 2025

1 AdaBelief

Год выхода: 2020

Гиперпараметры:

- **lr** - скорость обучения (значение по умолчанию: **1e-3**);
- **betas** - коэффициенты для вычисления средних значений градиента и их квадратов (значения по умолчанию: **(0.9, 0.999)**);
- **epsilon** - значения в знаменателе дроби, чтобы избежать деления на ноль или близкой к нулю величине (значение по умолчанию: **1e-8**);
- **weight_decay** - снижение весов (L2-регуляризация) (значение по умолчанию: **0**);
- **amsgrad** - использовать ли вариант **AMSGrad** для этого алгоритма (значение по умолчанию: **False**);
- **weight_decouple** - использовать ли уменьшение весов как в **AdamW** (значение по умолчанию: **False**);
- **fixed_decay** - используется, если для параметра **weight_decay** установлено значение **True**. Уменьшение весов выполняется по формуле: $W_{new} = W_{old} - W_{old} \times decay$, если **False**: $W_{new} = W_{old} - W_{old} \times decay \times lr$ (значение по умолчанию: **False**);
- **rectify** - выполняет обновление, аналогично **RAdam** (значение по умолчанию: **False**).

Идея: Интуитивный подход к **AdaBelief** заключается в том, чтобы адаптировать размер шага в соответствии с "верой" в текущее направление градиента. Рассматривая экспоненциальную скользящую среднюю (ЕМА) затуманенного градиента как предсказание градиента на следующем временном шаге, если наблюдаемый градиент сильно отличается от предсказания, мы не доверяем текущему наблюдению и делаем небольшой шаг; если

наблюдаемый градиент близок к прогнозируемому, мы доверяем ему и делаем большой шаг вперед. Авторы утверждают достоверность данных в ходе обширных экспериментов, показывающих, что он превосходит другие методы благодаря быстрой сходимости и высокой точности при классификации изображений и языковом моделировании.

Источник: [5]

2 Lion

Год выхода: 2023

Гиперпараметры:

- **lr** - скорость обучения (значение по умолчанию: **1e-4**);
- **betas** - коэффициенты для вычисления средних значений градиента и их квадратов (значения по умолчанию: **(0.9, 0.99)**);
- **weight_decay** - снижение весов (L2-регуляризация) (значение по умолчанию: **0**);
- **use_triton** - использовать **Triton** (значение по умолчанию: **False**);
- **decoupled_weight_decay** - использовать ли независимый спад весов (значение по умолчанию: **False**).

Идея: Использование знака градиента и инерции для обновления весов модели. В отличие от адаптивных методов, таких как **Adam**, **Lion** применяет одинаковую величину обновления для каждого параметра, определяемую через функцию знака. Это позволяет **Lion** уменьшить потребление памяти и скорость работы, поскольку он отслеживает только моментум, а не вторые моменты градиента.

Источник: [2]

3 AdaHessian

Год выхода: 2020

Гиперпараметры:

- **lr** - скорость обучения (значение по умолчанию: **0.15**);
- **betas** - коэффициенты для вычисления средних значений градиента и их квадратов (значения по умолчанию: **(0.9, 0.999)**);
- **epsilon** - значения в знаменателе дроби, чтобы избежать деления на ноль или близкой к нулю величине (значение по умолчанию: **1e-4**);
- **weight_decay** - снижение весов (L2-регуляризация) (значение по умолчанию: **0**);

- **hessian_power** - степень гессиана (значение по умолчанию: **1**);
- **spatial_average_block_size** - Пространственный средний размер блока для одномерных тензоров (значения по умолчанию: **(-1, -1, -1, -1)**).

Идея: **AdaHessian** использует информацию о гессиане (вторых производных) для адаптации скорости обучения, что улучшает сходимость.

Источник: [4]

4 Fromage

Год выхода: 2020

Гиперпараметры:

- **lr** - скорость обучения (значение по умолчанию: **1e-2**);
- **p_bound** - ограничивает оптимизацию ограниченным набором.

Идея: Fromage сочетает адаптивную нормализацию градиента с контролем нормы весов, что способствует стабильности и эффективности обучения.

Источник: [1]

5 AdaBound

Год выхода: 2019

Гиперпараметры:

- **lr** - скорость обучения **Adam** (значение по умолчанию: **1e-3**);
- **betas** - коэффициенты для вычисления средних значений градиента и их квадратов (значения по умолчанию: **(0.9, 0.999)**);
- **final lr** - окончательная (**SGD**) скорость обучения (значение по умолчанию: **1e-1**);
- **gamma** - скорость сходимости для граничной функции (значение по умолчанию: **1e-3**);
- **epsilon** - значения в знаменателе дроби, чтобы избежать деления на ноль или близкой к нулю величине (значение по умолчанию: **1e-8**);
- **weight_decay** - снижение весов (L2-регуляризация) (значение по умолчанию: **0**);
- **amsgrad** - использовать ли вариант **AMSGrad** для этого алгоритма (значение по умолчанию: **False**).

Идея: AdaBound адаптирует скорость обучения с динамическими границами, переходя от адаптивных методов к SGD по мере обучения, что обеспечивает быструю сходимость и хорошую обобщающую способность.

Источники: [3]

Список литературы

- [1] Jeremy Bernstein и др. «On the distance between two neural networks and the stability of learning». В: *Neural Information Processing Systems*. 2020.
- [2] Xiangning Chen и др. *Symbolic Discovery of Optimization Algorithms*. 2023. URL: <https://arxiv.org/abs/2302.06675>.
- [3] Liangchen Luo и др. «Adaptive Gradient Methods with Dynamic Bound of Learning Rate». В: *Proceedings of the 7th International Conference on Learning Representations*. New Orleans, Louisiana, май 2019.
- [4] Zhewei Yao и др. «ADAHESIAN: An Adaptive Second Order Optimizer for Machine Learning». В: *AAAI (Accepted)* (2021).
- [5] Juntang Zhuang и др. «AdaBelief Optimizer: Adapting Stepsizes by the Belief in Observed Gradients». В: *Conference on Neural Information Processing Systems* (2020).